مشروع توظيف الذكاء الاصطناعي في استخراج بيانات التجارب العشوائية وتحليلها

AI-assisted Structured Data Extraction, Evidence Synthesis & Predictive Analytics from Randomized Controlled Trials (RCTs)

> **الفكرة الأساسية:** تحويل المعلومات الواردة داخل أوراق الـRCTs من نصوص وجداول يصعب على الكمبيوتر تحليلها مباشرة إلى بيانات منظمة داخل Excel/CSV، مع فصل كل قيمة ونوعها ووحدتها والمقارنة المرتبطة بها، ثم جمع بيانات دراسات متعددة وتحليلها باستخدام أدوات إحصائية وذكاء اصطناعي مناسبة.

1. خلفية المشروع والمشكلة

بدأ التدريب باستخراج المتغيرات يدويًا من ورقة RCT وإدخالها في Excel. كان الهدف أن يمثّل كل عمود خاصية واحدة واضحة، وأن يمكن قراءة كل صف باعتباره وصفًا مفهومًا لبيان محدد في الدراسة. هذه العملية قد تستغرق قرابة **4 ساعات لكل دراسة** وفق تجربة الفريق، وهو ما يجعل تطبيقها على عشرات أو مئات الدراسات مرهقًا.

عند تجربة أدوات ذكاء اصطناعي عامة وكتابة prompts مفصلة، لم تكن النتائج دائمًا دقيقة أو ملتزمة بالبنية المطلوبة؛ لذلك فالتحدي ليس كتابة prompt وحده، بل تصميم **منظومة استخراج معيارية قابلة للتحقق** تمنع دمج المتغيرات أو اختراع قيم أو فقد سياق الجداول.

2. الأهداف

1. بناء قاموس موحّد للمتغيرات (Data Dictionary) وقالب Excel/CSV بمعايير صارمة.
2. تطوير عملية استخراج مدعومة بالـAI من الأوراق البحثية مع إسناد كل قيمة إلى مصدرها.
3. توحيد المتغيرات وربطها عبر عدد كبير من دراسات RCT مع الاحتفاظ باختلافات المجموعات والنتائج والزمن.
4. إجراء تحليل وصفي، وتقييم إمكانية meta-analysis، واختبار إمكانات النمذجة التنبؤية عند توافر بيانات مناسبة.
5. قياس دقة النظام وتوفير الوقت مقارنةً بالاستخراج اليدوي.

3. المرحلة الأولى — إعداد البيانات واستخراجها آليًا

الخطوة 1: تحديد وحدة البيانات ونطاقها

تحديد مستوى السجل قبل البدء: **الدراسة**، أو **ذراع التدخل**، أو **النتيجة عند نقطة زمنية معينة**. لا يُنصح بوضع كل تفاصيل دراسة كاملة في صف واحد؛ الأفضل فصل الكيانات المرتبطة بجداول/صفحات متعددة، بحيث يمثّل كل صف حقيقة محددة ذات معرفات تربطها بالدراسة والمجموعة والزمن.

الخطوة 2: إنشاء Data Dictionary

تحديد اسم كل حقل، معناه، نوع البيانات، وحدته، القيم المسموحة، كيفية تسجيل القيم المفقودة، وقواعد المقارنة والمجالات. مثال: age_mean_value رقمي، وage_unit نص موحّد (years).

الخطوة 3: التفكيك إلى خلايا ذرّية (Atomic Fields)

- لا تُكتب 65 mg في خلية واحدة: نفصل value = 65 وunit = mg.
- لا تُكتب ≥18 years كقيمة وحيدة: نفصل operator = >= وvalue = 18 وunit = years.
- لا تُكتب 20–65 years داخل خانة واحدة: نفصل min = 20 وmax = 65 وunit = years.
- عند الحاجة إلى رايات المقارنة (is_greater_than / is_equal / is_less_than) تُنشأ كأعمدة منفصلة وفق قاموس البيانات، لكن عادةً يكفي عمود operator مضبوط القيم لتفادي التضارب.

الخطوة 4: بناء مسار استخراج قابل للمراجعة

PDF → text/tables extraction → study segmentation → AI structured extraction → schema validation → source verification → Excel/CSV export.

يجب أن يلتقط النظام عنوان الجدول والصفحة والاقتباس النصي القصير الذي يسند كل قيمة، ويضع not_reported عند غياب البيانات بدل الاستنتاج. كما يجب حفظ نسختَي النص الأصلي والقيمة القياسية، وعدم تحويل الوحدات دون تسجيل التحويل.

4. مثال عملي: تصميم الجداول

يمكن تنظيم المصنف في أوراق مستقلة: Studies, Arms, Outcomes, Eligibility, Provenance, Validation_Log. المثال التالي يوضّح **سجلاً واحدًا لمعيار عمر** ضمن جدول أهلية المريض؛ الأرقام توضيحية وليست مأخوذة من دراسة حقيقية.

study_id	criterion	operator	value	min_value	max_value	unit	source_page
RCT_001	age	>=	18			years	4
RCT_002	age	between		20	65	years	6

في جدول النتائج، نحتاج أيضًا study_id, arm_id, outcome_name, timepoint, sample_size, mean, sd, events, total, effect_measure, confidence_interval, unit بحسب نوع النتيجة. القاعدة: عدم خلط أنواع النتائج أو الأساس الإحصائي في نفس الأعمدة من دون توصيف.

5. استراتيجية الـAI Prompting الصحيحة

1. إعطاء الـAI **تعريفًا دقيقًا للمهمة**: استخراج حقائق فقط، لا تلخيص أو تفسير.
2. تمرير **Schema ثابت**، ويفضّل JSON Schema مع حقول وأنواع وقيم مسموحة.
3. تزويده **بأمثلة إدخال وإخراج صحيحة** تشمل ≤ و≥ والمدى والوحدات والقيم المفقودة.
4. تقسيم الورقة إلى أقسام/جداول لتقليل السهو، ثم دمج النتائج بمعرفات ثابتة.
5. فرض **التحقق الآلي** من أنواع الحقول والقيود، ثم مراجعة بشرية للقيم الحرجة والعينات.
6. تكرار تحسين الـprompt باستخدام مجموعة اختبار ثابتة، وليس الاكتفاء بأن المخرجات تبدو منسّقة.

Prompt أولي للاختبار (بالإنجليزية)

```
You are a clinical-trial data extraction assistant.
Extract only explicitly reported facts from the provided RCT text.
Return VALID JSON matching the supplied schema; no prose.
Each field must contain a single atomic fact.
Separate numeric value, comparison operator, and unit.
For ranges, use min_value and max_value separately.
Keep study_id, arm_id, outcome, and timepoint context.
For every extracted record, include source_page and exact_source_text.
If a fact is absent or unclear, use null and mark review_required=true.
Never infer, calculate, or invent missing values.
Do not merge treatment arms or timepoints.
Before returning, check field types, allowed operators, and units.
```

ملحوظة: هذا **قالب أولي**، وليس Prompt نهائيًا؛ يُستكمل بمخطط JSON وقاموس متغيرات وأمثلة حقيقية من الدراسات المستهدفة.

6. ضبط الجودة وتقييم نجاح المرحلة الأولى

إنشاء Gold Standard من دراسات يستخرجها باحثان يدويًا، ثم مقارنة AI بها على مستوى الحقول. تُحسب دقة/استرجاع القيم، مطابقة الوحدات والمعاملات والمدى، نسبة القيم المدعومة بمصدر صحيح، الزمن لكل دراسة، ونسبة الحالات التي تتطلب مراجعة بشرية. تُراجع الأخطاء ويُحسّن النظام قبل توسيع الاستخدام.

7. المرحلة الثانية — توحيد الأدلة وتحليلها

الخطوة 7: Identification & Harmonization

عند إدخال دراسات كثيرة، تُطابق المتغيرات المتشابهة رغم اختلاف الأسماء (مثل BMI / body mass index)، وتُوحّد الوحدات والتعاريف ونقاط القياس. وفي الوقت نفسه يجب الحفاظ على الاختلافات المهمة في السكان والتدخلات والمقارنات ومقاييس النتائج.

الخطوة 8: تحليل وصفي وتجميع الأدلة

إنشاء وصف لتوزيع المتغيرات، تعداد التدخلات والنتائج، واكتشاف النواقص والتباين بين الدراسات. وإذا كان سؤال البحث وتصميم الدراسات والبيانات المستخرجة مناسبين، يمكن إجراء systematic review / meta-analysis وفق بروتوكول ومنهجية مستقلة؛ مجرد تجميع الجداول لا يحوّل المشروع تلقائيًا إلى مراجعة منهجية أو إرشاد علاجي.

الخطوة 9: Predictive Analytics — وفق نوع البيانات

عند توافر بيانات فردية للمرضى (IPD) وبأذونات مناسبة، يمكن بناء نموذج يتنبأ بنتيجة معينة اعتمادًا على خصائص المرضى، مع تقسيم بيانات التدريب والاختبار والتحقق الخارجي، وتقييم التحيّز والمعايرة.

عند توافر نتائج مجمّعة منشورة فقط لا يجوز افتراض القدرة على التنبؤ بمخاطر مريض فردي؛ يمكن بدلاً من ذلك تحليل العلاقات على مستوى الدراسة، أو meta-regression إذا توافرت شروطها، مع الانتباه لخطر الاستدلال البيئي الخاطئ.

> **تمييز علمي مهم:** ما تبدأون به يُسمّى بدقة structured data extraction / data curation، وهو جزء تمهيدي من مسار أشمل يمكن أن يشمل data mining. التحليل والتنبؤ مرحلتان تاليتان، ولا يثبت نموذج ارتباطًا سببيًا أو تشخيصًا لمجرد تحليل بيانات منشورة.

8. نواتج المشروع المقترحة

1. قالب Excel/CSV وData Dictionary وJSON Schema موحد.
2. مجموعة تجارب RCT مستخرجة يدويًا للتحقق المرجعي.
3. Prompt/نظام AI لاستخراج البيانات مع سجلات المصادر والأخطاء.
4. مجموعة بيانات موحّدة من الدراسات المستهدفة، مع تقارير جودة.
5. تحليل إحصائي أولي وتقييم جدوى meta-analysis أو التنبؤ بحسب البيانات.
6. تقرير مقارنة بين الاستخراج اليدوي والآلي: الدقة، الزمن، والقيود.

9. خطوات البدء المقترحة

تجربة أولية: اختيار 5–10 دراسات RCT ضمن موضوع علاجي واحد؛ الاتفاق على قائمة المتغيرات؛ بناء Excel وSchema؛ استخراج يدوي مرجعي؛ تجربة AI على الدراسات نفسها؛ مراجعة الأخطاء؛ ثم اختبار النسخة المحسنة على دراسات إضافية لم تستخدم أثناء التطوير.

هذا المستند ينظم فكرة المشروع كما وردت في المحادثة، ويضيف الضوابط المنهجية اللازمة لتحويلها إلى مشروع بحثي قابل للتنفيذ.